

Detecção Automática de Tuberculose Utilizando Redes Neurais Convolucionais

Gabriel Garcez Barros Sousa¹, Vandecia Rejane Monteiro Fernandes²

¹ Ciência de Computação

Universidade Federal do Maranhão (UFMA) – São Luis – MA – Brasil

²Engenharia de Computação

Universidade Federal do Maranhão (UFMA) – São Luis – MA – Brasil

galemalian@hotmail.com, vandecia@ecp.ufma.br

Abstract. One of the most common examinations done in hospitals is the chest radiograph. From the result of this exam, many illnesses can be diagnosed, such as Pulmonary Tuberculosis, which is within the top 10 most lethal illnesses in the world. The main objective of this work is to propose a convolutional neural network model that is able to diagnose Tuberculosis through chest radiographs. With this model, the creation of a system that can assist specialists to find a diagnosis quicker will be possible, which will lower work load and possible diagnosis subjectivity.

Resumo. Um dos exames mais comuns realizados em hospitais é a radiografia do tórax. Do resultado desse exame podem ser diagnosticadas muitas doenças, como a Tuberculose Pulmonar, que se encontra entre as 10 doenças mais letais da atualidade. O principal objetivo deste trabalho é propor um modelo de rede neural convolucional que realiza o diagnóstico de tuberculose por radiografias do tórax. Com este modelo gerado, será possível a criação de um sistema que possa auxiliar especialistas a encontrar um diagnóstico, diminuindo a carga de trabalho do mesmo e ainda reduzindo a subjetividade no estudo da radiografia.

Palavras-chaves: Radiografia, Diagnóstico, Deep Learning, Rede Neural Convolucionais, Tuberculose.

1. Introdução

Doenças encontradas no pulmão e coração são geralmente doenças que trazem riscos letais para as pessoas. Como exemplo, têm-se a Tuberculose Pulmonar (TBP) que se encontra na lista das 10 doenças mais letais do mundo, afetando mais de 10 milhões de pessoas em 2017 [WHO 2018]. Essa doença e várias outras encontradas no tórax conseguem ser curadas com mais efetividade quanto mais cedo for determinado o diagnóstico.

O exame mais utilizado para a detecção de doenças de coração e pulmão é a radiografia do tórax, também conhecido como raio-X do tórax. Tal procedimento gera uma imagem 2D que representa a parte interna da região por meio do uso de radiação ionizante na forma de raios X e é de fácil aquisição, substituindo o exame físico para especialistas de pulmão.

A análise desse exame consiste no estudo do mesmo com o âmbito de encontrar anomalias presentes na região. As anomalias variam por doença e se manifestam de diversas formas como pontos no pulmão, tamanho de pulmão, coração alterado, etc. Um diagnóstico preciso de uma radiografia requer bastante observação e experiência do especialista e esse fato pode resultar em diagnósticos diferentes para a mesma imagem.

O fato de existirem diversas formas de anomalias torácicas se manifestando torna o problema adequado para ser resolvido por meio do uso de *Deep Learning*. *Deep Learning* é uma área de aprendizado de máquina que se baseia em abstrair informações complexas, como imagens, por meio de profundas camadas de processamento.

Um modelo que faz uso de *Deep Learning* tem a capacidade de diferenciar e classificar imagens e é bastante utilizado na área médica para o diagnóstico de doenças, através de exames que geram imagens ou volumes. Como exemplo, *Deep Learning* foi aplicado na detecção de glaucoma[Cerentini A. 2017] e tumores cerebrais[Mohammad Havaei 2017], apresentando acurácia e *dice score* de 90% e 0.83 respectivamente.

Em [Paras Lakhani 2017] e [Rahul Hooda 2017], foram propostos dois modelos de redes neurais convolucionais (CNN) para a detecção de Tuberculose Pulmonar, apresentando resultados de acurácia de 94% e taxa de AUC de 0.99 respectivamente. Esses valores demonstram que a rede apresenta boa capacidade de trabalhar com radiografias em busca de tuberculose.

O diagnóstico de doenças do tórax é um processo que somente pode ser confirmado por médicos e que pode resultar em diagnósticos diferentes dependendo do especialista. Realizar uma radiografia do tórax é um ato comum em hospitais [Kelly 2012], sendo que todos os dias são geradas imagens que devem ser bem analisadas por esses médicos.

Com isso, este trabalho visa implementar um aplicativo para a sugestão de diagnóstico de Tuberculose Pulmonar (TBP), combinando o poder de extração de características e de classificação da Rede Neural Convolucional para criar modelos que possam automaticamente identificar, através de imagens de raio-X do tórax, sugestões de tuberculose em um paciente, com a ideia de acelerar o processo de diagnóstico desta doença.

Para acelerar o processo e diminuir a variação de diagnósticos diferentes, a utilização de métodos automáticos para realizar esses procedimentos é apropriado. O uso desses métodos deve reduzir a carga de trabalho de hospitais e ainda oferecer uma segunda opinião aos médicos, criando a oportunidade de diagnósticos mais precisos.

2. Metodologia

A metodologia utilizada neste trabalho foi organizada em 5 etapas: (1) aquisição e preparação da base de radiografias; (2) estabelecimento do espaço de busca para encontrar o modelo de CNN mais eficiente e preciso para o problema; (3) treino dos modelos gerados pelo algoritmo de busca; (4) teste e validação dos modelos encontrados para determinar o mais eficiente; (5) Desenvolvimento do aplicativo.

Durante a pesquisa por bases de imagens, foram encontradas duas bases que apresentam e classificam as imagens de radiografia de tórax com a presença de TBP. Tais bases são a Montgomery County chest X-ray set (MC) e a Shenzhen chest X-ray set

Figura 1. Imagem de raio-X do tórax

Fonte - [Jaeger S 2014]

(SC) [Jaeger S 2014]. A MC apresenta um total de 138 imagens de diversos tamanhos e formatações e a SC apresenta 615, mas com dimensões mais uniformes. A figura 1 apresenta um exemplo de imagem da base.

Devido à quantidade grande de imagens, a resolução foi diminuída para diminuir a necessidade de poder computacional para realizar o treino. Além disso, as imagens também foram convertidas para escala de cinza, mas devido às imagens serem radiografias, não perdeu-se informação nessa conversão. Essas duas ações abrangem por completo a etapa de pré-processamento do trabalho.

O modelo de *Deep Learning* utilizado neste trabalho é a rede neural convolucional (CNN). Essa rede aplica o uso de camadas de filtros convolucionais para extrair e aprender características de imagens de uma forma parecida como animais percebem e representam informação visual. Tal rede é bastante utilizada para a classificação de imagens médicas e apresenta bons resultados na literatura, como foi visto na seção de trabalhos relacionados.

O maior empecilho da rede é o tempo demorado de treino de modelos e de encontrar modelos e parâmetros adequados para o problema a ser atacado.

As bibliotecas usadas para a implementação dos módulos do aplicativo foram Keras e Hyperas. O Keras fornece funções de fácil desenvolvimento de redes neurais complexas e robustas utilizando uma biblioteca de tensores. A biblioteca de tensores utilizada no aplicativo foi o Tensorflow [Abadi et al. 2015]. A outra biblioteca principal utilizada foi o Hyperas. Essa biblioteca oferece funções que automatizam a busca por modelos e hiper parâmetros eficientes, dado um espaço de busca.

Para a implementação dos módulos do aplicativo, foi utilizada a linguagem Python (Versão 3.7) com a IDE PyCharm [Islam 2015], o construtor de GUI para Python wxPython [Robin Dunn 2003] e as bibliotecas previamente mencionadas.

Foram aplicadas as funcionalidades de *Deep Learning* das bibliotecas estudadas junto com as imagens das bases encontradas para o desenvolvimento do modelo usado no aplicativo. Nesta etapa também foi desenvolvido uma interface visual funcional do aplicativo.

O foco do estudo das bibliotecas foi aprender a como fazer uso das funções necessárias para implementar e treinar um modelo eficiente que consiga interpretar imagens de raio-X do tórax e sugerir um diagnóstico de TBP.


3. Resultados

Junto com o modelo inicial da Rede Neural Convolucional foi desenvolvida uma função de leitura das centenas de imagens de radiografia, para pré-processá-las e ter um tamanho menor com somente um canal de cor. As imagens foram diminuídas pois originalmente apresentavam dimensões inviáveis para treino. As dimensões das imagens utilizadas pelo modelo são de 300x300 pixels.

A função de carregar e pré-processar a grande quantidade de imagens se comportou adequadamente. O modelo inicial desenvolvido apresentou resultados favoráveis para um modelo que não passou pelo processo de otimização de hiper parâmetros. A busca por modelos e hiper parâmetros eficientes foi realizada com sucesso, mas necessitou do uso de computadores mais potentes que o esperado e foi o processo mais demorado do projeto.


A figura 2 mostra a acurácia pelo processo de treino do melhor modelo encontrado, que apresentou uma acurácia final de 80.9% no conjunto de testes com uma distribuição equilibrada de casos positivos e negativos para tuberculose. Uma versão inicial da interface gráfica foi desenvolvida e pode ser vista na figura 3.

Figura 2. Acurácia pelo treino



Fonte - Acervo do autor

Figura 3. Imagem da interface gráfica inicial



Fonte - Acervo do autor

4. Conclusão

Este trabalho teve como objetivo o desenvolvimento de um aplicativo para a classificação de imagens de raio-X do tórax, combinando o poder de extração de características e de classificação de uma Rede Neural Convolucional para criar modelos que identificam automaticamente casos de tuberculose em pacientes, visando acelerar o processo de diagnóstico dessa doença.

Todas as tarefas desenvolvidas geraram resultados positivos, mas que ainda podem ser melhorados em trabalhos futuros. A taxa de acerto de 80% é um valor aceitável, mas outras técnicas de pré-processamento podem ser exploradas a fim de aumentar a acurácia. A interface gráfica também deverá ser melhorada para aceitar várias imagens ou até poder corrigir a classificação caso o médico perceba que o sistema tenha errado.

Referências

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., and Zheng, X. (2015). TensorFlow: Large-scale machine learning on heterogeneous systems. Software available from tensorflow.org.
- Cerentini A., Welfer D., C. d. M. P. H. C. J. D. G. N. (2017). Automatic identification of glaucoma using deep learning methods. *Studies in Health Technology and Informatics*, 2017.
- Islam, Q. N. (2015). *Mastering PyCharm*. Packt Publishing Ltd.

- Jaeger S, Candemir S, A. S. W. Y. L. P. T. G. (2014). Two public chest x-ray datasets for computer-aided screening of pulmonary diseases.
- Kelly, B. (2012). The chest radiograph. *Ulster Medical Society*, 81(3):143 – 148.
- Mohammad Havaei, e. a. (2017). Brain tumor segmentation with deep neural networks. *Medical Image Analysis*, 35:18 – 31.
- Paras Lakhani, B. S. (2017). Deep learning at chest radiography: Automated classification of pulmonary tuberculosis by using convolutional neural networks. *Radiology*, 284(2):574 – 582.
- Rahul Hooda, e. a. (2017). Deep-learning: A potential method for tuberculosis detection using chest radiography. pages 497–502.
- Robin Dunn, P. O. (2003). wxpython. <https://wxpython.org/>.
- WHO, W. H. O. (2018). Global tuberculosis report 2018.